

Clasificación y Regresión Avanzadas

De los modelos lineales a los modelos más potentes del machine learning clásico. Este documento explora la evolución desde técnicas básicas hacia algoritmos sofisticados capaces de capturar patrones complejos en los datos.

El Mapa del Aprendizaje Supervisado

La evolución del machine learning clásico sigue una progresión natural: desde reglas simples hacia la combinación inteligente de múltiples modelos que trabajan en conjunto.



Regresión

Modelos lineales básicos con ecuaciones simples



Árboles

Reglas de decisión jerárquicas y estructuradas



Ensambles

Combinación de múltiples modelos para mayor precisión

Árboles de Decisión: La Idea Central

Los árboles de decisión son modelos que dividen los datos en grupos cada vez más homogéneos. Cada rama del árbol representa una regla basada en el valor de una variable específica, creando una estructura jerárquica de decisiones.



Nodo Raíz

Punto de partida con todos los datos




Ramas


Reglas de división basadas en variables



Hojas


Predicciones finales para cada grupo






Cómo Decide un Árbol


Un árbol toma decisiones mediante preguntas sucesivas del tipo "¿Variable X es mayor que Y?" Cada bifurcación divide los datos en subgrupos más puros hasta llegar a las hojas finales.



Primera División
¿Ingreso > \$100,000?



Segunda División
¿Edad > 35 años?



Predicción Final
Clase o valor asignado

Métricas de División: Pureza de Nodos


Para elegir la mejor división en cada nodo, los árboles utilizan métricas que miden la homogeneidad o pureza de los grupos resultantes. Cuanto más homogénea sea una hoja, mejor será la predicción.

Índice de Gini

Mide la impureza como probabilidad de clasificación incorrecta

Entropía

Mide el desorden o incertidumbre en los datos



Ventajas y Limitaciones

✓ Fáciles de Visualizar

La estructura del árbol es intuitiva y se puede representar gráficamente, facilitando la interpretación de las decisiones del modelo.

✓ Capturan No Linealidades

A diferencia de la regresión lineal, los árboles pueden modelar relaciones complejas y no lineales entre variables sin transformaciones previas.

✗ Pueden Sobreajustar

Sin control, los árboles crecen demasiado profundos y memorizan el ruido del conjunto de entrenamiento en lugar de aprender patrones generales.


✗ Inestables

Pequeños cambios en los datos pueden resultar en árboles completamente diferentes, lo que afecta su robustez y confiabilidad.

Árboles de Regresión

A diferencia de la clasificación, los árboles de regresión predicen valores numéricos continuos. En lugar de asignar clases, cada hoja contiene un valor promedio calculado a partir de las muestras que caen en ella.

El resultado visual es una función escalonada: regiones planas en lugar de líneas rectas como en regresión lineal. Esto permite capturar patrones complejos manteniendo simplicidad interpretativa.



Ejemplo típico: Predecir el monto esperado de venta según variables como ubicación geográfica, temporada del año y características del producto.

Control del Sobreajuste

Para evitar que los árboles memoricen el ruido del entrenamiento, aplicamos técnicas de regularización mediante hiperparámetros que limitan su complejidad.



Profundidad Máxima

Limita cuántos niveles puede tener el árbol. Menos profundidad = modelo más simple y general.



Mínimo de Muestras

Establece cuántas observaciones debe haber en un nodo antes de dividirlo o en una hoja final.



Poda (Pruning)

Elimina ramas que aportan poco a la predicción, simplificando el árbol después del entrenamiento.

Regularizar = simplificar para generalizar mejor

Limitaciones de los Árboles Individuales

Alta Varianza

Pequeños cambios en los datos producen árboles muy diferentes, afectando la estabilidad de las predicciones.

Peor Desempeño en Datasets Grandes

Un solo árbol puede no capturar toda la complejidad de conjuntos de datos extensos con muchas variables.

Solución: En lugar de confiar en un único árbol, combinamos múltiples árboles para obtener predicciones más robustas y precisas. Así nacen los métodos de ensamble.








Ensamblados: La Idea Fundamental

Más modelos = menos error

Los métodos de ensamble combinan las predicciones de múltiples modelos simples (débiles) para crear un modelo robusto (fuerte). Esta estrategia reduce tanto la varianza como el sesgo, mejorando significativamente el desempeño predictivo.

En lugar de buscar el árbol perfecto, entrenamos muchos árboles buenos y dejamos que "voten" o promedien sus predicciones. El resultado final es más confiable que cualquier modelo individual.



Tipos de Ensamblés

Bagging

Bootstrap Aggregating: entrena modelos en paralelo sobre muestras aleatorias con reemplazo

Boosting

Entrenamiento secuencial donde cada modelo corrige los errores del anterior

Stacking

Combina diferentes tipos de modelos usando un meta-modelo que aprende a integrar sus predicciones

Bagging: Bootstrap

Aggregating

Bagging entrena varios modelos de forma independiente, cada uno sobre una muestra diferente extraída con reemplazo del dataset original. Las predicciones finales se obtienen promediando (regresión) o votando (clasificación).

Muestreo Bootstrap
Crear múltiples subconjuntos



Entrenar Modelos
Cada árbol aprende independientemente

Agregar Resultados
Promedio o votación mayoritaria

Ejemplo emblemático: Random Forest utiliza bagging con árboles de decisión, agregando aleatoriedad adicional en la selección de variables para cada división.



Random Forest en Acción

Funcionamiento

Random Forest construye decenas o cientos de árboles de decisión. Cada árbol ve una muestra aleatoria diferente de los datos (bootstrap) y en cada división considera solo un subconjunto aleatorio de variables.

100+

Árboles Típicos

Cantidad común en producción

Predicción Final

El resultado final es un consenso: en clasificación, la clase más votada; en regresión, el promedio de las predicciones. Esta diversidad reduce errores individuales.

33%

Variables Aleatorias

Subconjunto por división

Ventajas y Desventajas del Bagging

✓ Reduce la Varianza

Al promediar múltiples modelos, las fluctuaciones individuales se cancelan, produciendo predicciones más estables.

✓ Más Estable

Menos sensible a cambios en los datos de entrenamiento o a valores atípicos que podrían afectar un árbol individual.

✗ Menor Interpretabilidad


Un bosque de 100 árboles es imposible de visualizar completamente. Perdemos la simplicidad interpretativa de un árbol único.

✗ Mayor Cómputo


Entrenar y predecir con múltiples modelos requiere más tiempo y recursos computacionales que un modelo simple.

Boosting: Aprendizaje Secuencial

A diferencia de Bagging, Boosting entrena modelos de forma secuencial. Cada nuevo modelo se enfoca en corregir los errores cometidos por los anteriores, asignando mayor peso a las observaciones mal predichas.



Ejemplos populares: XGBoost, LightGBM, AdaBoost, Gradient Boosting Machines (GBM).



Cómo Piensa el Boosting

Boosting construye una secuencia de modelos donde cada uno intenta mejorar el resultado global. En lugar de entrenar independientemente, cada modelo "aprende de los errores" acumulados.

El resultado final es una suma ponderada de todos los modelos débiles, produciendo un modelo fuerte con menor sesgo y mayor precisión.



Gradient Boosting y XGBoost

Gradient Boosting construye árboles que predicen el gradiente del error, optimizando iterativamente una función de pérdida. XGBoost es su implementación más avanzada, añadiendo regularización, procesamiento paralelo y manejo inteligente de valores faltantes.

Regularización L1/L2

Controla la complejidad del modelo para evitar overfitting


Tree Pruning

Poda inteligente que elimina ramas que no aportan ganancia significativa

Velocidad Optimizada

Algoritmos paralelos que aceleran el entrenamiento dramáticamente

Gradient Boosting Optimization



Hiperparámetros Clave en XGBoost



max_depth

Profundidad máxima de cada árbol. Mayor profundidad = mayor complejidad y riesgo de overfitting.



learning_rate

Tasa de aprendizaje que controla cuánto contribuye cada árbol. Valores menores requieren más árboles.



n_estimators

Número total de árboles a entrenar. Más árboles = mejor ajuste pero mayor tiempo de cómputo.



subsample

Fracción de muestras para entrenar cada árbol. Reduce overfitting añadiendo aleatoriedad.

Comparativa: Bagging vs Boosting

Característica	Bagging	Boosting
Objetivo Principal	Reducir varianza	Reducir sesgo
Tipo de Entrenamiento	Paralelo (independiente)	Secuencial (iterativo)
Velocidad	Más rápido (paralelizable)	Más lento (secuencial)
Riesgo de Sobreajuste	Bajo	Medio-Alto si no se regulariza
Ejemplo Representativo	Random Forest	XGBoost / LightGBM
Uso Típico	Modelos robustos generales	Competencias, máxima precisión

Ambos enfoques superan significativamente a los árboles individuales. La elección entre uno u otro depende del problema, los datos disponibles y los recursos computacionales.



Stacking: Meta-Aprendizaje

Stacking es una combinación jerárquica de modelos distintos. Varios modelos base (nivel 0) generan predicciones que se usan como features para un modelo final (nivel 1). Este meta-modelo aprende cómo ponderar óptimamente cada predicción base.

0

1 Entrenar Modelos Base

Random Forest, XGBoost, SVM, etc. en el dataset original

0

2 Generar Predicciones

Cada modelo produce predicciones mediante validación cruzada

0

3 Meta-Modelo Final

Regresión logística o Ridge aprende a combinar predicciones base

Ejemplo Práctico de Stacking

Modelos Base (Nivel 0)

- Random Forest (500 árboles)
- XGBoost (100 iteraciones)
- Regresión Logística
- Support Vector Machine

Meta-Modelo (Nivel 1)

Regresión logística simple que aprende los pesos óptimos para combinar las 4 predicciones base. Las predicciones del nivel 0 se convierten en features del nivel 1.

El resultado típicamente supera el rendimiento de cualquier modelo individual, combinando la robustez de Random Forest con la precisión de XGBoost y la simplicidad de modelos lineales.

Comparativa General de Modelos

Modelo	Precisión	Interpretabilidad	Cómputo	Ideal para
Árbol de Decisión	Media	Alta	Bajo	Pequeños datasets
Random Forest	Alta	Media	Medio	Tabulares complejos
XGBoost	Muy alta	Baja	Alto	Grandes volúmenes
Stacking	Muy alta	Muy baja	Muy alto	Competiciones ML

La elección del modelo depende del contexto: si necesitas explicar decisiones, prioriza interpretabilidad; si buscas máxima precisión en producción, considera XGBoost o stacking.

AutoML: Democratizando el Machine Learning

Selección de Algoritmos
Prueba automática de múltiples
modelos

Modelo Final
Pipeline listo para producción



Optimización de
Hiperparámetros
Búsqueda inteligente del mejor
configuración

Validación Cruzada
Evaluación robusta del rendimiento

Plataformas AutoML Populares

Google AutoML

Integración con GCP, excelente para imágenes y texto, interfaz visual intuitiva.

H2O AutoML

Open source, soporte para R y Python, leaderboard automático de modelos.

Auto-sklearn

Basado en scikit-learn, meta-aprendizaje, ideal para investigación y prototipado.

AutoML acelera el desarrollo sin sacrificar rigor científico, permitiendo a equipos pequeños competir con recursos limitados.

Explainable AI: La Necesidad de Transparencia



¿Por Qué Explicabilidad?

Necesitamos entender por qué un modelo toma ciertas decisiones, especialmente en aplicaciones críticas como salud, finanzas o justicia. La explicabilidad construye confianza, permite debugging efectivo y cumple requisitos regulatorios.

- Cumplimiento legal (GDPR, etc.)
- Detección de sesgos
- Mejora continua del modelo
- Confianza del usuario final

SHAP: SHapley Additive exPlanations

SHAP calcula el impacto de cada variable en la predicción usando valores de Shapley de la teoría de juegos. Proporciona explicaciones consistentes y matemáticamente rigurosas que muestran cuánto contribuye cada feature al resultado final.

Global Importance

Ranking de variables más
influyentes en todo el dataset

Local Explanation


Desglose de factores para una
predicción individual específica

Dependence Plots

Relación entre valor de feature y
su impacto en predicción

Visualización SHAP: Ejemplo

En un modelo de aprobación de crédito, SHAP permite visualizar qué factores empujan la predicción hacia "aprobar" o "rechazar". Los valores positivos aumentan la probabilidad de aprobación, los negativos la disminuyen.



Métricas de Evaluación

Avanzadas

0.89

AUC-ROC

Mide la capacidad del modelo para discriminar entre clases a través de todos los umbrales posibles

0.76

F1-Score

Balance entre precisión y recall, especialmente útil en datasets desbalanceados

0.15

Log Loss

Penaliza predicciones incorrectas con alta confianza, evaluando probabilidades calibradas

0.94

Precisión

Proporción de predicciones positivas correctas sobre el total de positivas predichas

Elegir la métrica correcta es tan importante como elegir el modelo. En producción, considera múltiples métricas que reflejen los objetivos de negocio.

De los modelos clásicos al aprendizaje profundo

Modelos Clásicos

Los modelos tradicionales como árboles de decisión, regresiones y ensambles trabajan con variables predefinidas. Aprenden relaciones directas entre características diseñadas por humanos.

- Variables creadas manualmente
- Relaciones explícitas
- Interpretación clara


Redes Neuronales

Las redes neuronales descubren representaciones abstractas automáticamente de los datos crudos. Inspiradas en el cerebro: neuronas conectadas que activan patrones complejos.

- Aprendizaje de características
- Patrones ocultos
- Descubrimiento automático

📌 **Idea clave:** No programamos reglas explícitas — el modelo las descubre directamente de los datos mediante aprendizaje automático.

Anatomía de una red neuronal





Funcionamiento matemático

Cada neurona ejecuta un cálculo fundamental que combina entradas ponderadas con un sesgo, transformadas por una función de activación:


$$y = f(W \cdot X + b)$$

donde W representa pesos, X las entradas, b el sesgo, y f la función de activación (ReLU, Sigmoid, Tanh).





De redes simples a Deep Learning



Red Neuronal Básica (MLP)

Una única capa oculta procesa información. Suficiente para problemas simples con relaciones moderadamente complejas.



Múltiples Capas Ocultas

Al agregar capas, nace el deep learning. Cada nivel aprende abstracciones progresivamente más sofisticadas de los datos.



Jerarquía de Conceptos

Las capas iniciales detectan patrones simples (bordes, texturas). Las capas profundas comprenden conceptos complejos (objetos, contexto).

Capas Iniciales

- Patrones básicos
- Características simples
- Bordes y texturas

Capas Intermedias

- Combinaciones
- Formas compuestas
- Partes de objetos

Capas Profundas

- Conceptos abstractos
- Objetos completos
- Contexto semántico



Requisitos clave: Deep learning demanda grandes volúmenes de datos y capacidad computacional significativa. Las GPUs y TPUs aceleran el entrenamiento multiplicando la velocidad de cálculo matricial.

Aplicaciones y panorama actual

Visión por Computadora

Las redes convolucionales (CNN) procesan imágenes detectando patrones espaciales jerárquicos — desde píxeles hasta objetos completos.

Procesamiento del Lenguaje

Redes recurrentes (RNN/LSTM) y transformadores (GPT, BERT) comprenden texto capturando dependencias y contexto lingüístico.

Series Temporales

Arquitecturas especializadas analizan datos secuenciales: predicción financiera, análisis de voz, monitoreo de sensores IoT.

Tendencias actuales en IA

Modelos

Preentrenados
Redes neurales entrenadas en grandes conjuntos de datos, reduciendo tiempo y recursos necesarios.

Transfer Learning

Adaptación de conocimiento de un dominio a otro, maximizando eficiencia con datos limitados.

IA Generativa

Creación de contenido nuevo: imágenes, texto, música mediante modelos como GANs, difusión y LLMs.

Idea final: Deep Learning no reemplaza al machine learning clásico — lo expande hacia problemas más ricos y complejos, abriendo fronteras antes inaccesibles.