


Procesamiento de Lenguaje Natural + Series de Tiempo

Cómo entender texto y predecir con datos temporales



¿Qué es una Serie de Tiempo?

Una serie de tiempo es una secuencia de observaciones tomadas en intervalos regulares a lo largo del tiempo. Cada punto de datos está indexado temporalmente, lo que permite analizar patrones, tendencias y comportamientos dinámicos.

Las series temporales son fundamentales en negocios: desde ventas diarias hasta tráfico web por hora, estos datos capturan cómo cambian las métricas clave. Su análisis permite no solo entender el pasado, sino también predecir el futuro con modelos estadísticos y de machine learning.

A diferencia de los datos transversales, las series temporales tienen dependencia temporal: el valor de hoy puede estar influenciado por los valores de ayer, la semana pasada o el mismo período del año anterior.



Componentes de una Serie de Tiempo

Toda serie temporal puede descomponerse en elementos fundamentales que revelan su estructura subyacente. Entender estos componentes es esencial para elegir el modelo de predicción correcto.

1

Tendencia

El movimiento de largo plazo de la serie.

Puede ser ascendente (crecimiento sostenido), descendente (declive) o estacionaria (sin dirección clara).

- Ventas que crecen año tras año
- Costos operativos en reducción
- Participación de mercado estable

2

Estacionalidad

Patrones que se repiten en intervalos fijos (mensual, trimestral, anual). Reflejan ciclos predecibles como temporadas, festividades o hábitos periódicos.

- Picos de ventas en diciembre
- Mayor tráfico web los lunes
- Demanda turística en verano

3

Ruido o Residuo

Fluctuaciones irregulares e impredecibles que no siguen patrones. Representan eventos aleatorios, errores de medición o factores no capturados por el modelo.

- Variaciones diarias inesperadas
- Eventos únicos sin recurrencia
- Error de medición o registro

Ejemplos de Series Temporales en Negocios

Las series de tiempo están presentes en prácticamente todas las métricas empresariales. Estos ejemplos ilustran cómo diferentes áreas de negocio dependen del análisis temporal para la toma de decisiones.

Ventas Mensuales
El tracking de ingresos a lo largo del tiempo revela patrones de crecimiento, impacto de campañas y estacionalidad. Permite proyectar ingresos futuros y establecer metas realistas.

Generación de Leads
Monitorear la adquisición de prospectos por día o semana ayuda a evaluar efectividad de marketing, optimizar inversión publicitaria y anticipar períodos de baja demanda.

Tasa de Morosidad
En finanzas, analizar defaults en el tiempo permite detectar deterioro en la cartera crediticia, ajustar políticas de riesgo y provisionar pérdidas anticipadamente.

Forecasting vs Nowcasting

Forecasting: Predecir el Futuro

El forecasting utiliza datos históricos para proyectar valores futuros. Es la aplicación más común de series temporales: desde predecir demanda del próximo trimestre hasta estimar ventas del próximo año.

Casos de uso:

- Planificación de inventario y producción
- Presupuestos y proyecciones financieras
- Dimensionamiento de capacidad operativa
- Estrategia de precios dinámicos

Los modelos de forecasting asumen que patrones pasados se mantendrán en el futuro, por lo que requieren actualización constante.

Nowcasting: Entender el Presente

El nowcasting estima el valor actual o muy reciente de una variable que aún no ha sido medida oficialmente. Es útil cuando los datos tienen retraso en su publicación.

Casos de uso:

- Estimar PIB antes de cifras oficiales
- Predecir ventas del mes en curso
- Evaluar tendencias de mercado en tiempo real
- Detectar cambios antes de reportes formales

El nowcasting combina múltiples fuentes de datos (redes sociales, búsquedas web, transacciones) para inferir el presente.

Modelos Clásicos de Series

Temporales

Antes de modelos complejos de machine learning, existen métodos estadísticos probados que ofrecen predicciones sólidas y son fáciles de interpretar. Estos modelos básicos sirven como línea base para comparar enfoques más sofisticados.

Método Naive

La predicción más simple: el valor futuro será igual al último valor observado.

Sorprendentemente efectivo para series con alta aleatoriedad o cambios bruscos.

Cuándo usar: Series muy volátiles, benchmark inicial, mercados impredecibles.

Promedio Móvil

Suaviza la serie tomando el promedio de las últimas n observaciones. Reduce ruido pero introduce retraso en la detección de cambios.

Cuándo usar: Datos con mucho ruido, detección de tendencias generales, alertas de anomalías.

Suavizado Exponencial

Pondera observaciones recientes más que las antiguas, capturando cambios recientes sin ignorar historia. Balance entre adaptabilidad e inercia.

Cuándo usar: Series con tendencia moderada, necesidad de respuesta rápida, datos con pocas observaciones.

Autocorrelación: La Memoria de las Series

La autocorrelación mide cuán relacionado está un valor con sus valores pasados. Es el concepto fundamental que diferencia series temporales de otros tipos de datos, ya que captura la dependencia temporal.

Función de Autocorrelación (ACF)

Mide la correlación entre la serie y sus versiones retrasadas (lags).

Un ACF alto en lag 12 significa que el valor de hoy se parece al de hace 12 períodos.

Interpretación:

- Decaimiento lento → Tendencia presente
- Picos en lags específicos → Estacionalidad
- Corte abrupto → Proceso de media móvil


Autocorrelación Parcial (PACF)

Mide la correlación entre la serie y un lag específico, removiendo el efecto de lags intermedios. Útil para identificar el orden de procesos autorregresivos.

Interpretación:

- Corte abrupto → Proceso autorregresivo
- Decaimiento lento → Proceso de media móvil
- Patrón en ambos → Modelo mixto (ARMA)

ARIMA: El Modelo Estándar Industrial



ARIMA (AutoRegressive Integrated Moving Average) es el modelo clásico más poderoso y flexible para series temporales. Combina tres componentes que capturan diferentes aspectos de los datos.

Componentes de ARIMA(p,d,q)

AR(p) - Autorregresivo: El valor actual depende de p valores pasados. Captura inercia y patrones de corto plazo.

I(d) - Integración: Número de diferenciaciones necesarias para hacer la serie estacionaria. Remueve tendencia.

MA(q) - Media Móvil: El valor actual depende de q errores de predicción pasados. Suaviza shocks aleatorios.

La clave de ARIMA es encontrar los valores óptimos de (p,d,q) mediante análisis de ACF/PACF, criterios de información (AIC, BIC) o validación cruzada. Modelos mal especificados producen predicciones pobres.

❏ **Extensiones populares:** SARIMA añade componentes estacionales, y SARIMAX incorpora variables exógenas (factores externos como promociones, clima, economía).

Evaluación de Modelos: Midiendo el Desempeño

Un modelo de forecasting solo es útil si sus predicciones son precisas. Estas métricas cuantifican qué tan bien el modelo captura patrones reales y permiten comparar diferentes enfoques.

MAE

Mean Absolute Error

Promedio de errores absolutos. Fácil de interpretar (mismas unidades que los datos).

Penaliza todos los errores por igual.

Uso: Métrica general, fácil de comunicar a stakeholders no técnicos.

RMSE

Root Mean Squared Error

Raíz del promedio de errores cuadrados.

Penaliza más los errores grandes. Sensible a outliers.

Uso: Cuando errores grandes son especialmente costosos (ej: stockouts, sobreproducción).

MAPE

Mean Absolute Percentage Error

Error promedio como porcentaje del valor real.

Permite comparar series con diferentes escalas.

Uso: Comparar precisión entre productos, regiones o períodos con magnitudes distintas.

Regla de oro: No existe una métrica perfecta. Usa múltiples métricas y valida en períodos hold-out (datos no vistos por el modelo) para evitar sobreajuste.

Ejercicio Práctico: Tu Primer Modelo de Serie Temporal

Paso a paso

- 0
- 1Cargar y explorar
- Importa datos históricos (ej: ventas mensuales). Visualiza la serie, identifica tendencia, estacionalidad y outliers.
- 0
- 2Preprocesar
- Maneja valores faltantes, aplica transformaciones (log, diferenciación) si es necesario para estabilizar varianza.
- 0
- 3Entrenar modelo
- Ajusta un modelo simple (ej: Holt-Winters o ARIMA). Divide datos en train/test para validación.
- 0
- 4Evaluar y predecir
- Calcula métricas en el conjunto de test. Genera forecast para períodos futuros y visualiza intervalos de confianza.



Al finalizar este ejercicio, habrás construido tu primer pipeline completo de forecasting: desde datos crudos hasta predicciones accionables. Este flujo se replica en proyectos reales, solo escalando complejidad según la necesidad del negocio.

 **Próximos pasos:** Experimenta con múltiples modelos, incorpora variables exógenas (promociones, clima, economía) y construye ensembles para mejorar precisión.